AdaMAS-unit：收尾导入检查与预算进化

方案与结果报告 · 截至 2026-11-12 · 题目 nl2_deepdiff · 预算档 tier50（B = 1,586,206 token）

摘要

1. 之前 held out 反馈半比率在同一策略下波动很大（0.086 到 0.281），主因是整个测试文件收集失败：最终代码缺少文档点名的名字，71 个收集失败的文件里 68 个属于这一类。
2. 为此给所有对照组加了同一个收尾导入检查和一次受限修补。修补全部成功的干净基线三次比率为 0.294 / 0.281 / 0.274，标准差从 0.083 降到 0.008，噪声阈值 ε = 0.01，候选需两轮都超过 0.2927。
3. 在新基线上重新开始预算进化。第 1 次迭代的候选表 v6 被拒（0.234 / 0.238），其中一轮修补被撤销，驱动程序按停止条件停下，等待决定。
4. 全部运行没有 CRITICAL 越界，没有运行作废。

1. 系统方案

AdaMAS-unit 把一个仓库的生成拆成固定顺序的五个单元，每个单元由一个智能体构建，通过冻结的验收门，失败时最多修复 3 次。一次完整的多单元运行称为一个轮回，所有单元共用一个预算账本（token、时钟、上下文压缩次数、修复次数）。轮回之间只有预算规划者在进化：进化者读账本里的数字，提出新的预算表（各单元份额、修复上限、审批参数）。

单元	名称	token 份额（π_0）
U1	foundation_contracts_and_utilities	0.20
U2	recursive_diff_engine	0.20
U3	delta_difference_application	0.20
U4	search_and_hash_features	0.20
U5	serialization_cli_and_public_integration	0.20

判定规则（E1）

- 第一优先：可提交（最终代码能导入、文档点名的名字能导入、考卷能收集）的轮回数不比现任差。
- 第二优先：held out 反馈半比率。两轮都高于现任均值 + ε 接受；两轮都不高于均值拒绝；其余加第 3 轮，3 轮中至少 2 轮高于均值 + ε 才接受。
- ε = max(现任各轮极差的一半, 0.01)。冻结考卷通过数、过门单元数、浪费只记录，不参与判定。
- 最多 5 次迭代，连续 2 次被拒就停。进化者只看到 U1 到 U5 的匿名编号和数字，看不到代码、测试或单元真名。

held out 与沙盒

- held out 按函数、按测试文件分层、固定种子拆成两半：反馈半 303 个函数，评估半 302 个函数。评估半留给 E2，至今没有读取，也没有计算。
- held out 只由密封程序读取，只输出数字。参考实现在反馈半上的比率为 0.9703，评分链路已核对。
- 所有智能体会话和工作区代码都在沙盒内运行。每次回报都包含沙盒越界警告一节。

2. 问题诊断：反馈半比率为什么波动大

对补丁前的 10 个轮回逐个文件做收集与运行（只用反馈半，只输出数字）。比率 = 收集率 × 收集后通过率。

轮回	收集率	收集后通过率	比率	收集不到的文件 / 22
cal-pi0-r3	0.409	0.323	0.132	6
tier50-pi0-r3	0.337	0.255	0.086	9
tier50-pi0-r4	0.614	0.457	0.281	6
tier50-pi0-r5	0.327	0.414	0.135	10

轮回	收集率	收集后通过率	比率	收集不到的文件 / 22
tier75-pi0-r3	0.376	0.289	0.109	7
tier75-pi0-r4	0.667	0.233	0.155	5
tier75-pi0-r5	0.327	0.263	0.086	10
tier100-pi0-r3	0.848	0.311	0.264	2
e1-i1-v1-r1	0.327	0.293	0.096	10
e1-i1-v1-r2	0.396	0.275	0.109	6

- 对数方差分解（全部 10 次）：收集率约占 2/3，收集后通过率约占 1/4。比率与收集率的相关是 0.85，收集率与收集后通过率几乎不相关（0.10）。
- 71 个收集不到的文件里，68 个是属性或名称错误：held out 文件导入的名字，最终代码里没有。
- 和哪个单元没做完关系不明显：cal-pi0-r3 五个单元全过门、冻结考卷 52/52，收集率却只有 0.41。

这 68 个缺失名字在文档里的情况

类别	文件数
1. 文档写了名字和所在模块	65（其中 60 个正是从文档写的模块导入）
2. 文档写了名字，没写模块	0
3. 文档里没有这个名字	3

顺带发现：设计文档用多行括号形式的 from deepdiff.x import (...) 列出公开接口，AdaMAS 原来的提取规则读不到这种写法，按旧规则这 68 个会全部被算作“文档没写”。之前在 AdaMAS 上做的天花板分析，可能因此低估了“文档写了却没做对”的比例。这一点已记入 AdaMAS-unit 的 EXPERIMENT_LOG。

3. 方案：所有对照组统一的收尾导入检查

目的是去掉“名字是否碰巧对上”带来的噪声，对所有组同样处理，不给任何组额外优势。

环节	做法
导入清单	只由设计文档推导，所有轮回开始前冻结（184 个名字：115 个写明模块，69 个没写；16 个模块；0 个命令行入口）。所有组共用一份，记录哈希。
检查	程序完成，不调模型；在沙盒内、代码副本上运行：清单名字能导入、包内模块能导入、__all__ 名字存在、命令行入口能打印帮助。
单元结束时	只检查和记录缺失了哪些名字，不修补。缺失数（只给数量）提供给进化者作诊断。
最终提交前	有问题时启动一次修补会话：15 万 token、600 秒、改动不超过 150 行。用独立账本，不计入轮回预算，不影响规划者。
修补范围（程序检查）	只能是导入、导出、__all__、缺失名字的最小定义，以及只含导入和对允许名字赋值的 try/except ImportError。不得改已有函数或类。违反任一条就整体撤销，恢复修补前的代码。
没写模块的名字	只记录，不检查、不修补（其中混有 conftest fixture、nox 会话、pytest 钩子，空跑时每次会报 36 到 63 个缺失）。

正对照最终 80/80 通过，覆盖：清单不含 held out 或密封路径；检查不改动工作目录；合法修补保留、越界修补撤销；修补不计入轮回账本；两组共用同一模块；不启用时行为与补丁前逐字节一致；进化者输入只有数量、没有名字。

4. 基线结果

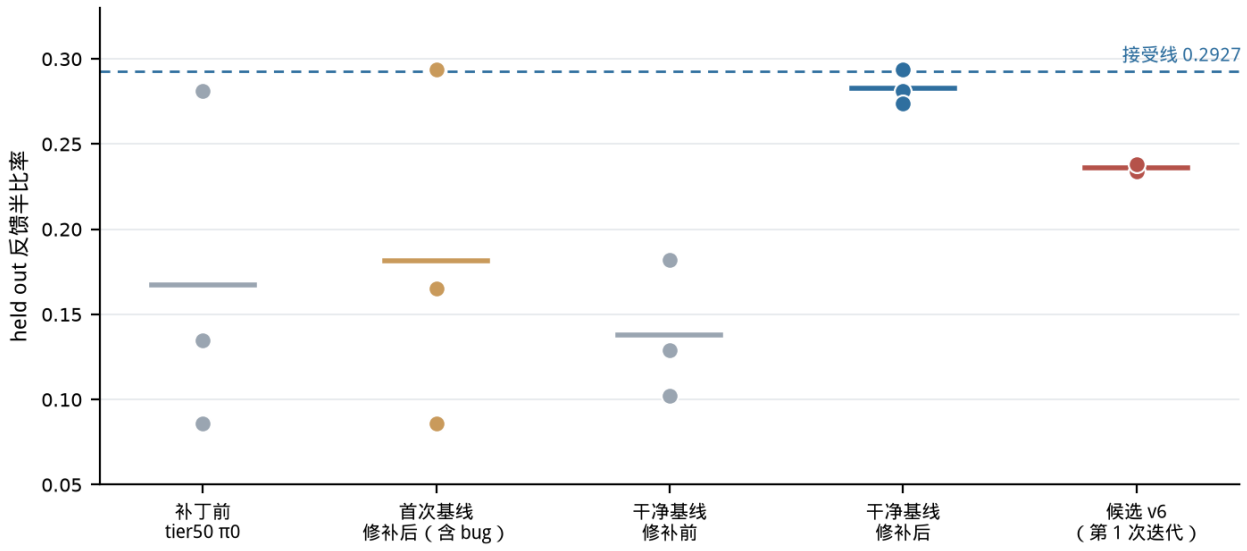


图 1 各组 held out 反馈半比率（点为单轮，横线为均值；虚线为新基线下的接受线）

首次基线（tier50-ic，3 轮）

轮回	修补	问题数 前→后	比率 前 / 后	说明
r1	撤销	22→22	0.086 / 0.086	try/except 导入当时不在规则内（且改写了已有名字）
r2	撤销	13→13	0.165 / 0.165	范围检查的 bug：同名函数定义两次被误判为修改
r3	保留	32→0	0.125 / 0.294	收集率 0.337→0.848

bug 已修复并补正对照；按决定允许受限的 try/except 导入。这组结果被 bug 污染，不用于判定。

干净基线（tier50-ic2，3 轮）

轮回	修补	问题数 前→后	修补用量 token / 秒 / 行	比率 前→后	收集率 前→后	收集后通过率	冻结 / 过门
r1	保留	38→0	108,318 / 78 / 71	0.182→0.294	0.49→0.87	0.336	45 / 3
r2	保留	11→0	70,393 / 50 / 24	0.129→0.281	0.37→0.85	0.331	46 / 3
r3	保留	26→0	88,148 / 59 / 60	0.102→0.274	0.33→0.85	0.323	49 / 4

范围	均值	极差	标准差
补丁前 tier50（参考）	0.167	0.195	0.083
干净基线，修补前	0.138	0.079	0.033
干净基线，修补后	0.283	0.020	0.008

修补成功后收集率稳定在 0.85 到 0.87，剩下的差别在收集后通过率（0.32 到 0.34），反映的是功能实现本身。新基线：现任为 π_0，$\varepsilon = \max(0.0099, 0.01) = 0.01$，接受线 0.2927。

5. 预算进化 E1 v3：第 1 次迭代

进化者的输入在开跑前新增了每个单元结束时缺失的名字数（只给数量）。候选表 v6：

单元	U1	U2	U3	U4	U5
token 份额（π_0 为 0.20）	0.17	0.18	0.18	0.21	0.26
修复上限（π_0 为 3）	1	1	2	3	3

审批参数：追加上限按后续单元的表内份额预留（later_table_shares）；每个单元追加总量不超过其初始分配（unit_topup_limit = 1）。

进化者的理由（摘要）

- U5 每轮都最后耗尽，缺失名字最多，修复常常空启动，因此把 U5 份额提到允许上限 0.26，保留 3 次修复。

- U4 两次没过门，份额提到 0.21、修复上限 3；U1、U2 一直过门，降份额、修复上限降到 1。
- 审批参数改动是为了防止前面单元的追加吃掉 U5 的预算。

结果

轮回	可提交	比率	修补	冻结考卷	过门单元数
r1	1	0.234	保留（9→0，17,715 token，31 行）	48	0
r2	0	0.238	撤销（18→18，97,020 token，57 行）	39	1

- 判定：拒绝（可提交为 0 的轮回比现任多）。两轮比率也都低于现任均值 0.283。用量 320 万 token，在预估 340 万以内。
- r2 的修补为补上缺失的 not_found，先定义了一个不在清单里的私有辅助类 _NotFound，按规则整体撤销。这是规则在起作用，不是 bug。
- 参考重放（不参与判定）：允许该辅助类时 r2 问题数降到 0，比率 0.261，仍低于 0.283。所以拒绝不是修补失败造成的。
- 推测：把前面单元的修复上限压到 1、限制追加，使前面单元做得更差（r1 五个单元都没过门），问题累积到后面。这一点尚待数据验证。

6. 沙盒越界警告

批次	运行数	WARNING	CRITICAL	作废
首次基线 tier50-ic	3	4（写 /tmp 被拦下）	0	0
干净基线 tier50-ic2	3	1（写 /tmp 被拦下）	0	0
E1 v3 第 1 次迭代	2	2（写 /tmp 被拦下）	0	0

所有 WARNING 都是构建者或修复者往 /tmp 写临时文件，被沙盒拦下，没有越界成功的命令。

7. 用量

项目	约 token
首次基线（3 轮 + 修补）	490 万
干净基线（3 轮 + 修补）	490 万
E1 v3 第 1 次迭代	320 万
补丁之后合计	约 1,300 万

进化剩余上限约 2,200 万；如有候选被接受，与 π_0 的配对确认（各 3 轮）另需约 1,000 万。

8. 当前状态与待决事项

> 数据状态（2026-11-12 发现）：本机的 /root/projects/AdaMAS-unit 和 /root/projects/AdaMAS 目前是空目录，轮回数据（outputs/，未纳入 git）在本机上已不可见。代码在 GitHub 上保存到提交 f9fb1df；此后的本地提交 4855fb9（进化者输入加缺失名字数、驱动程序停止条件）尚未推送，在本机上也已不可见。本报告的数字来自运行时的记录。继续实验前需要先确认数据能否恢复，或在新环境中重建。

- 修补能否定义只供缺失名字使用的私有辅助名（如 _NotFound）。建议保持严格规则：v6 的结论不受影响，放宽后修补更容易夹带新逻辑。
- 是否继续第 2 次迭代；修补被撤销时，是每次停下，还是按实际结果计入并在回报中标出。
- 提交 4855fb9 的恢复：若本地副本无法找回，需要按本报告第 5 节所述的改动重新实现并再过正对照。